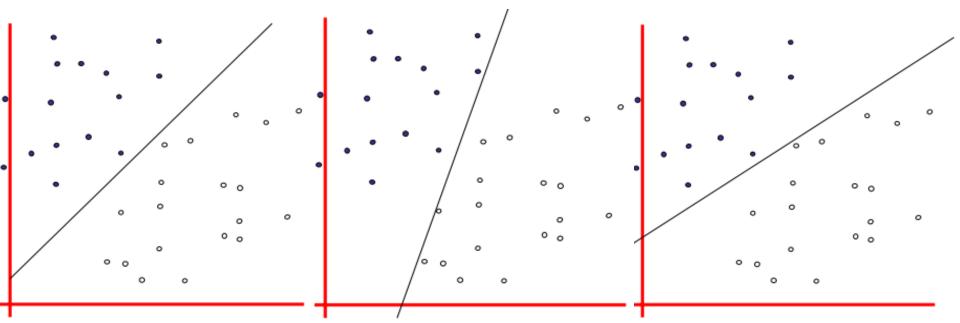


Máquinas de Vetores de Suporte

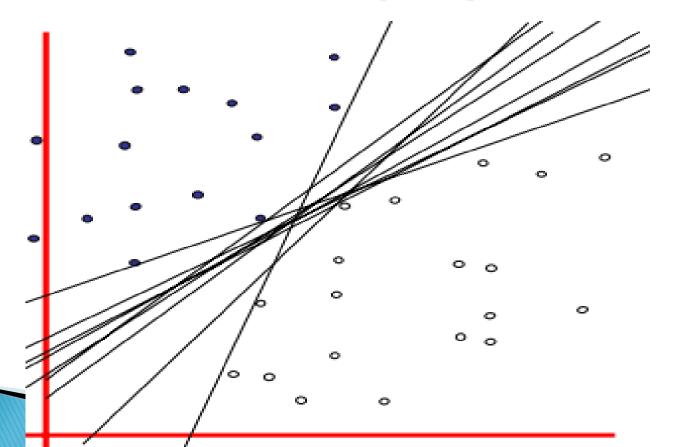
Jones Granatyr

Introdução

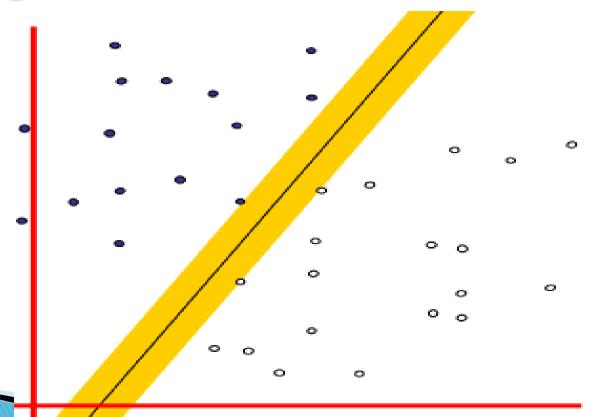
 Aprende hiperplanos de separação com margem máxima



Qual o melhor hiperplano?

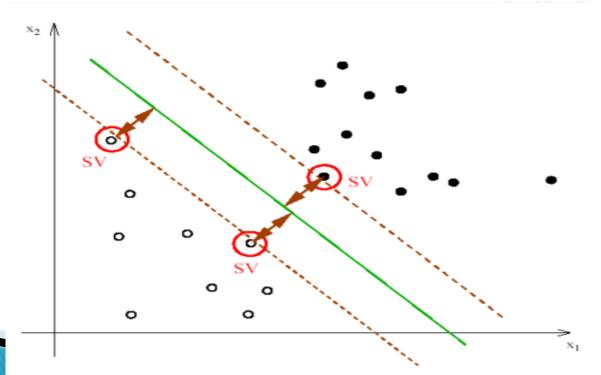


Margem máxima

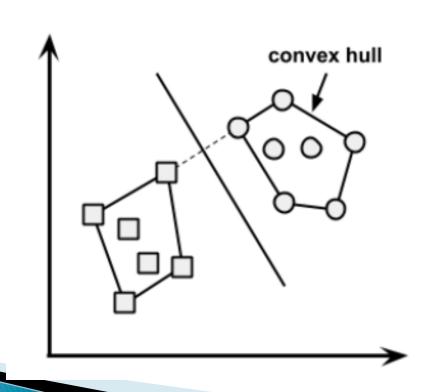


Vetores de suporte

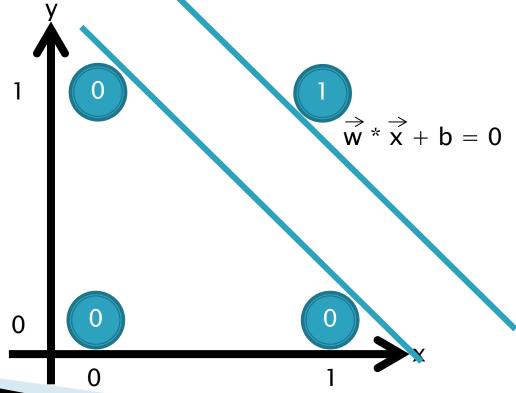
Reconstrução do hiperplano



Criação do hiperplano - Convex hulls (envoltória convexa)



Criação do hiperplano - abordagem matemática

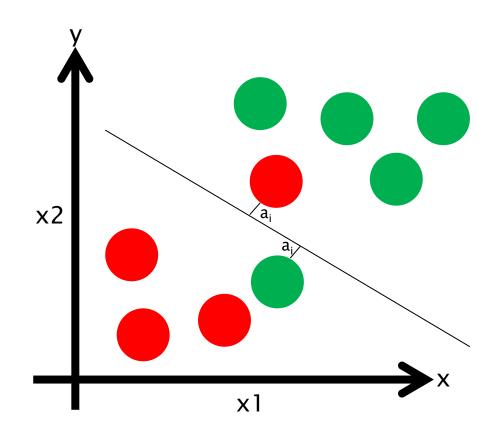


Erros e custo

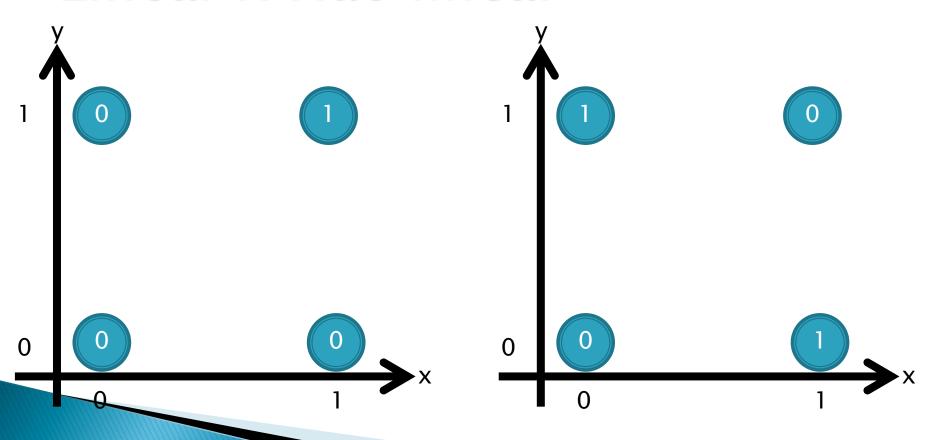
$$\frac{1}{2}|w|^2+c\sum_i a_i$$

c= punição por classificação incorreta

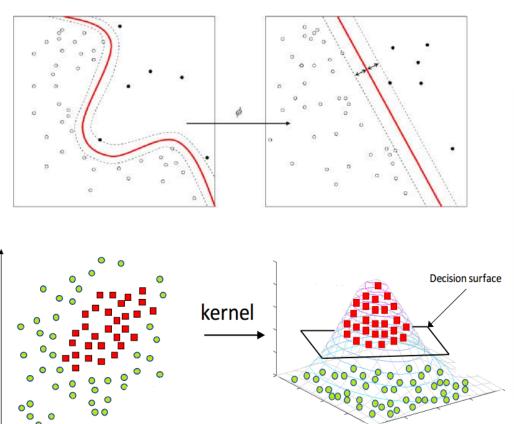
c alto = tenta 100% de separação c baixo = permite mais erros

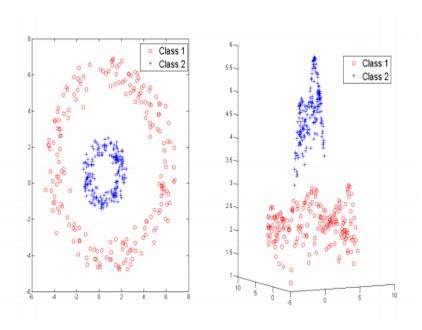


Linear x Não linear

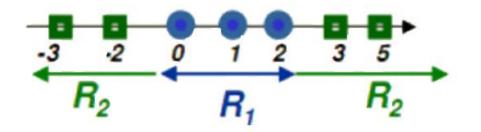


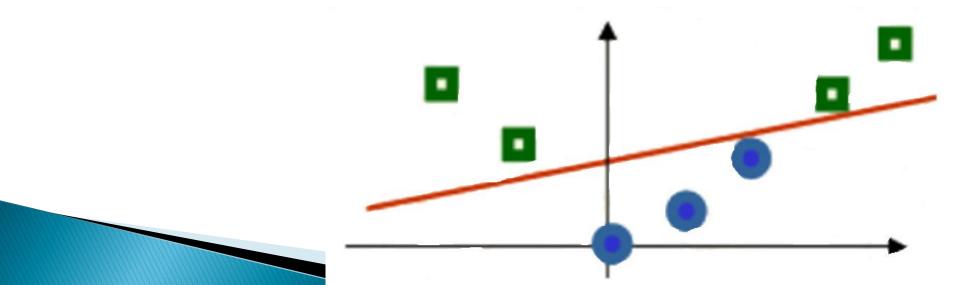
SVMs não lineares (Kernel Trick)





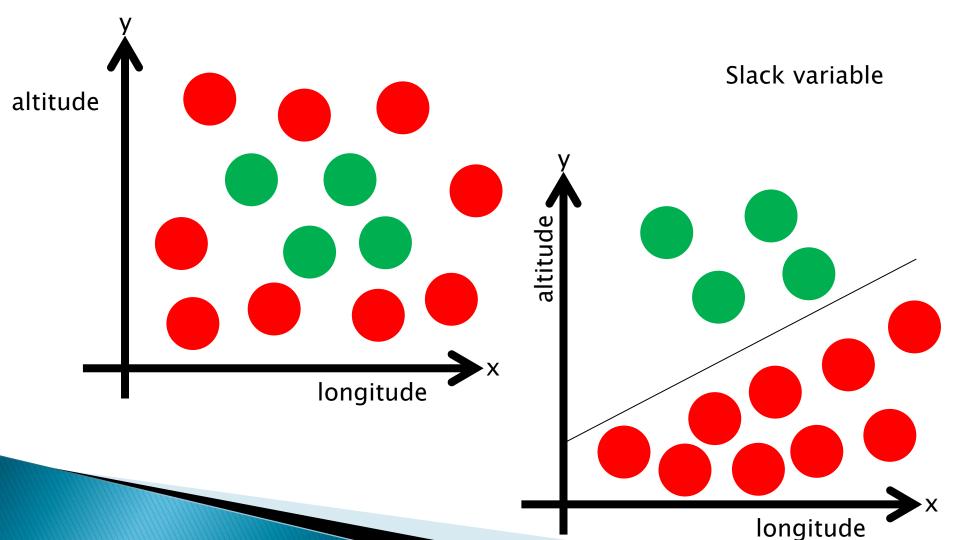
SVMs não lineares (Kernel Trick)





Kernels

Kernel	Inner Product Kernel
Linear	$K(x,y) = (x \cdot y)$
Gaussian	$K(x,y) = \exp\left(-\frac{\ x-x_i\ ^2}{2\sigma^2}\right)$
Polynomial	$K(x,y) = (x \cdot y)^p$
Tangent Hyperbolic	$K(x,y) = \tanh(x \cdot y - \Theta)$



SVM

- Vantagens
 - Não é muito influenciado por ruídos nos dados
 - Utilizado para classificação e regressão
 - Aprende conceitos não presentes nos dados originais
 - Mais fácil de usar do que redes neurais
- Desvantagens
 - Testar várias combinações de parâmetros
 - Lento
 - Black box

Conclusão